

Proyecto ABP

Minería de datos

Evidencia de Aprendizaje N°2: Preparación y análisis de relaciones

Integrantes:

- Marini Ian - 38409531
- Robles Emilce – 37093958

Profesora: Corso, Cynthia

2026

1. **NOMBRE DEL PROYECTO:** Análisis de factores de riesgo asociados a la diabetes mediante técnicas de exploración de datos en población adulta
2. **TIPO DE PROYECTO:** Proyecto de **investigación con enfoque tecnológico**, orientado al análisis de datos mediante técnicas de minería de datos.
3. **ESPACIO CURRICULAR O ESPACIOS PARTICIPANTES EN EL MÓDULO:** Minería de Datos
4. **OBJETIVO DE LA EVIDENCIA:** Preparar los datos del dataset seleccionado y analizar la relación entre variables asociadas a la presencia de diabetes en población adulta.
Esta segunda evidencia continúa el trabajo iniciado en la Evidencia N° 1. En esta etapa se profundiza el análisis mediante el tratamiento de datos, la construcción de un dataset final, el análisis bivariado y la interpretación de relaciones entre variables.
5. **PROBLEMÁTICA Y PREGUNTA DE ANÁLISIS:** La diabetes es una enfermedad crónica de alta prevalencia y se encuentra asociada a diversos factores de salud y hábitos de vida. Por este motivo, resulta relevante analizar variables como el índice de masa corporal, la actividad física, el tabaquismo y la edad codificada por grupos etarios.
Pregunta de análisis: ¿Qué factores de salud y hábitos de vida están asociados a la presencia de diabetes en la población?

6. FUENTE Y DESCRIPCIÓN DEL DATASET: Fuente: Kaggle - Diabetes Health Indicators Dataset.

El dataset proviene del sistema BRFSS (Behavioral Risk Factor Surveillance System) del CDC, correspondiente al año 2015. Contiene información obtenida mediante encuestas de salud, hábitos y condiciones crónicas de la población adulta.

- Cantidad de registros originales: 253.680.
- Cantidad de variables originales: 22.
- Variables seleccionadas inicialmente: Diabetes_012, BMI, Age, PhysActivity y Smoker.

7. TRATAMIENTO DE LOS DATOS: En esta etapa se evaluó la calidad de los datos y se aplicaron transformaciones necesarias para mejorar su interpretación. El objetivo fue conservar la información original, pero expresarla de forma más clara para el análisis.

7.1 Valores faltantes

Se verificaron valores faltantes en las variables seleccionadas. El resultado fue cero valores faltantes en todas las variables analizadas, por lo que no fue necesario aplicar técnicas de imputación.

Variable	Valores Faltantes	Decisión tomada
Diabetes_012	0	Se conserva la variable.
BMI	0	Se conserva la variable.
Age	0	Se conserva la variable y se interpreta como grupo etario codificado.

PhysActivity	0	Se conserva la variable y se agrega etiqueta descriptiva.
Smoker	0	Se conserva la variable y se agrega etiqueta descriptiva.


7.2 Detección de outliers

Se revisaron valores atípicos en la variable BMI mediante boxplot y el criterio del rango intercuartílico (IQR).


- Límite inferior calculado: 13,5.
- Límite superior calculado: 41,5.
- Cantidad de outliers detectados: 9.847 registros.

Los outliers corresponden principalmente a valores elevados de índice de masa corporal, asociados a posibles casos de obesidad severa. Se decidió no eliminarlos porque representan casos posibles dentro del contexto de salud y pueden aportar información relevante para el análisis de diabetes.

Detección de outliers en BMI



Distribución del BMI (sin visualización de outliers)



7.3 Transformaciones realizadas

Se aplicaron transformaciones para mejorar la lectura del dataset y facilitar la interpretación de resultados.

Transformación	Descripción	Justificación
Renombrado de columnas	Se cambiaron nombres originales en inglés por nombres en español.	Mejorar la comprensión del análisis.
Conversión de tipos	Variables categóricas codificadas como float fueron convertidas a entero.	Representar correctamente categorías discretas.

Etiquetas descriptivas	Se agregaron descripciones para diabetes, actividad física y tabaquismo.	Facilitar lectura de gráficos e interpretaciones.
Categoría de BMI	Se creó una variable categórica: Bajo peso, Normal, Sobrepeso y Obesidad.	Permitir análisis más interpretativo del índice de masa corporal.

8. CONSTRUCCIÓN DEL DATASET FINAL:

Luego del tratamiento de los datos, se construyó un dataset final compuesto por 253.680 registros y 9 variables seleccionadas. Estas variables se consideran relevantes porque permiten analizar la relación entre estado de diabetes, condición física, hábitos de vida y grupos etarios.

Variable final	Descripción	Tipo
Estado_Diabetes	Estado de diabetes codificado: 0 no diabetes, 1 prediabetes, 2 diabetes.	Categórica codificada
Estado_Diabetes_Descripcion	Etiqueta descriptiva del estado de diabetes.	Categórica
BMI	Índice de masa corporal.	Numérica
Categoria_BMI	Clasificación del BMI en bajo peso, normal, sobrepeso u obesidad.	Categórica

Edad	Edad codificada por rangos o grupos etarios.	Numérica codificada
Actividad_Fisica	Indica si la persona realiza actividad física: 0 no, 1 sí.	Categórica codificada
Actividad_Fisica_Descripcion	Etiqueta descriptiva de actividad física.	Categórica
Fumador	Indica si la persona es fumadora: 0 no, 1 sí.	Categórica codificada
Fumador_Descripcion	Etiqueta descriptiva de tabaquismo.	Categórica

Observación metodológica: la variable Edad no representa años exactos, sino rangos etarios codificados. Por este motivo, las interpretaciones se realizan en términos de grupos etarios y no como edad exacta.

9. ANÁLISIS BIVARIAIDO:

El análisis bivariado permitió estudiar la relación entre el estado de diabetes y otras variables seleccionadas. Se utilizaron gráficos de caja y gráficos de barras apiladas para comparar distribuciones y proporciones.

9.1 Relación entre BMI y estado de diabetes

El gráfico muestra la distribución del índice de masa corporal según el estado de diabetes. Se observa que la mediana del BMI es menor en personas sin diabetes y aumenta en los grupos con prediabetes y diabetes. Esto sugiere una asociación entre mayor BMI y presencia de diabetes.




Figura 3. Relación entre BMI y estado de diabetes.

9.2 Relación entre actividad física y diabetes

La proporción de personas con diabetes es mayor en el grupo que no realiza actividad física. Esto indica que el sedentarismo puede estar asociado a una mayor presencia de diabetes dentro del dataset analizado.




Figura 4. Proporción de diabetes según actividad física.

9.3 Relación entre tabaquismo y diabetes

Se observa una leve mayor proporción de diabetes en personas fumadoras en comparación con no fumadoras. Sin embargo, la diferencia no permite afirmar que el tabaquismo sea un factor determinante por sí solo dentro de este análisis exploratorio.




Figura 5. Proporción de diabetes según tabaquismo.

9.4 Relación entre edad y diabetes

Las personas con diabetes tienden a ubicarse en grupos etarios más altos. Esto sugiere una relación entre el avance de la edad y una mayor presencia de diabetes en la población analizada.




Figura 6. Relación entre grupos etarios y diabetes.

10. ANALISIS MULTIVARIADO:

Para completar el análisis de relaciones, se plantea un análisis multivariado cruzando simultáneamente el estado de diabetes, la categoría de BMI y la actividad física. Este cruce permite observar si la presencia de diabetes varía cuando se combinan factores físicos y hábitos de vida.

Variables cruzadas	Objetivo del análisis	Interpretación esperada
Estado_Diabetes_Descripcion + Categoria_BMI + Actividad_Fisica_Descripcion	Evaluar cómo cambia la proporción de diabetes según la combinación de BMI y actividad física.	Comparar si los grupos con obesidad y sin actividad física presentan mayor proporción de diabetes.

Si la proporción de diabetes aumenta en personas con obesidad y sin actividad física, el resultado refuerza la idea de que la combinación entre exceso de peso y sedentarismo se asocia con mayor presencia de diabetes.

11. VISUALIZACIONES E INTERPRETACIÓN DE RESULTADOS:

Las visualizaciones fueron utilizadas para facilitar la comparación entre grupos y detectar patrones relevantes. En esta evidencia se incluyeron gráficos de caja para variables numéricas y gráficos de barras apiladas para variables categóricas.

Los boxplots permitieron comparar la distribución de BMI y edad codificada según el estado de diabetes.

Los gráficos de barras apiladas permitieron comparar proporciones entre actividad física, tabaquismo y estado de diabetes.

Las interpretaciones se realizaron de forma exploratoria, sin afirmar causalidad.

12. CONCLUSIÓN DE LA EVIDENCIA:

En esta segunda etapa se realizó la preparación de los datos mediante la revisión de valores faltantes, detección de outliers, transformación de variables y construcción de un dataset final. El dataset final quedó conformado por 253.680 registros y 9 variables relevantes para el análisis de diabetes.

Los resultados del análisis bivariado muestran que el índice de masa corporal, la actividad física y los grupos etarios presentan relaciones relevantes con el estado de diabetes. Las personas con diabetes tienden a presentar valores más altos de BMI, menor actividad física y pertenecer a grupos etarios más elevados. En el caso del tabaquismo, se observó una diferencia leve, pero no determinante dentro del análisis realizado.

A nivel metodológico, los datos presentan buena calidad, ya que no se detectaron valores faltantes en las variables seleccionadas. Los outliers de BMI fueron conservados porque representan casos posibles dentro del contexto de salud. Esta evidencia deja una base sólida para futuras etapas de minería de datos, incluyendo análisis predictivo o construcción de modelos de clasificación.

13. HERRAMIENTAS UTILIZADAS:

- Python: lenguaje utilizado para el análisis de datos.
- Jupyter Notebook / Google Colab: entorno utilizado para desarrollar el análisis.
- Pandas: librería utilizada para la carga, limpieza, transformación y análisis tabular.
- Matplotlib y Seaborn: librerías utilizadas para la generación de visualizaciones.
- Repositorio: https://github.com/emirobles/ISPC-Mineria_de_datos-2026

14. BIBLIOGRAFÍA:

- Teboul, A. (s. f.). Diabetes Health Indicators Dataset. Kaggle.
<https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>
- Centers for Disease Control and Prevention. (2015). Behavioral Risk Factor Surveillance System (BRFSS). CDC.
- Normas APA, 7ma edición.

