

Proyecto ABP

Minería de datos

Análisis de factores de riesgo asociados a la diabetes mediante técnicas de exploración de datos en población adulta

Evidencia de Aprendizaje N°3: Aplicación de técnicas de minería de datos predictivas

Nombre del proyecto:

Análisis de factores de riesgo asociados a la diabetes mediante técnicas de exploración de datos en población adulta.

Integrantes:

- Marini Ian – 38409531
- Robles Emilce - 37093958

Profesora: Corso, Cynthia

Año: 2026

1. Introducción

La presente evidencia continúa el trabajo desarrollado en las Evidencias de Aprendizaje N°1 y N°2. En las etapas anteriores se realizó la selección del problema, la descripción del dataset, el análisis de calidad de datos, la preparación de variables y el análisis exploratorio de relaciones entre factores de salud y presencia de diabetes.

En esta tercera etapa se aplica una técnica de minería de datos predictiva con el objetivo de construir un modelo capaz de clasificar el estado de diabetes de una persona a partir de variables asociadas a su condición física y hábitos de vida.

El problema general del proyecto se mantiene en torno a la siguiente pregunta de análisis:

¿Qué factores de salud y hábitos de vida están asociados a la presencia de diabetes en la población?

2. Objetivo de la evidencia

El objetivo de esta evidencia es aplicar una técnica predictiva de minería de datos sobre el dataset previamente preparado, evaluar el desempeño del modelo obtenido e interpretar sus resultados en relación con el problema planteado.

En particular, se busca construir un modelo de clasificación que permita predecir el estado de diabetes de una persona a partir de variables como índice de masa corporal, edad, actividad física y tabaquismo.

3. Dataset utilizado

Se utilizó el dataset preparado en la Evidencia N°2, derivado del dataset **Diabetes Health Indicators Dataset**, basado en datos del sistema BRFSS del CDC.

El dataset final utilizado para esta etapa contiene **253.680 registros** y variables relacionadas con el estado de diabetes, el índice de masa corporal, la edad codificada por grupos etarios, la actividad física y el tabaquismo.

En la etapa anterior se verificó que las variables seleccionadas no presentaban valores faltantes. También se detectaron valores atípicos en la variable BMI, pero se decidió conservarlos porque representan casos posibles dentro del contexto de salud, especialmente asociados a obesidad severa.

4. Selección de la variable objetivo

La variable objetivo seleccionada fue:

Estado_Diabetes_Descripcion

Esta variable representa el estado de diabetes de cada persona y clasifica los registros en las siguientes categorías:

Categoría	Descripción
No diabetes	Persona sin diagnóstico de diabetes
Prediabetes	Persona con condición de prediabetes
Diabetes	Persona con diabetes

La elección de esta variable se justifica porque el problema planteado busca analizar factores asociados a la presencia de diabetes en la población. Por lo tanto, predecir el estado de diabetes permite pasar de un análisis exploratorio a un análisis predictivo.

Además, al tratarse de una variable categórica, corresponde aplicar una técnica de **clasificación** y no una técnica de regresión.

5. Variables predictoras seleccionadas

Para construir el modelo se seleccionaron las siguientes variables predictoras:

Variable Original	Variable Modificada	Descripción
BMI	BMI	Índice de masa corporal
Age	Edad	Edad codificada por grupos etarios
PhysicalActivity	Actividad_Física	Indica si la persona realiza actividad física
Smoker	Fumador	Indica si la persona es fumadora

Estas variables fueron seleccionadas porque ya habían sido analizadas en las evidencias anteriores y presentan una relación conceptual con la problemática estudiada. El índice de masa corporal (BMI) es uno de los factores más frecuentemente asociados al desarrollo de diabetes tipo 2, debido a su relación con el sobrepeso y la obesidad. La edad permite analizar diferencias entre grupos etarios y evaluar cómo aumenta el riesgo a medida que la población envejece. Por su parte,

la actividad física constituye un indicador de hábitos saludables que puede contribuir a la prevención de enfermedades metabólicas, mientras que el tabaquismo representa un factor de riesgo asociado a diversas condiciones crónicas que afectan el estado general de salud.

La selección de estas variables busca representar tanto características físicas como hábitos de vida de las personas, permitiendo construir un modelo capaz de identificar patrones asociados a la presencia de diabetes en la población analizada.

Se decidió no utilizar la variable Estado_Diabetes como variable predictora, ya que representa la misma información que la variable objetivo, aunque codificada numéricamente. Su inclusión generaría fuga de información (data leakage), provocando una evaluación artificialmente elevada y resultados poco representativos del desempeño real del modelo.

6. Técnica predictiva aplicada

La técnica predictiva seleccionada fue un **Árbol de Decisión**.

La elección de esta técnica se realizó considerando tanto las características del dataset como el objetivo del proyecto. Dado que la variable objetivo corresponde a categorías discretas (No diabetes, Prediabetes y Diabetes), se determinó que el problema debía abordarse mediante una técnica de clasificación.

Esta técnica fue seleccionada por tres motivos principales:

- Es adecuada para problemas de clasificación con variables categóricas y numéricas, permitiendo predecir la categoría a la que pertenece cada registro.
- Permite interpretar visualmente las reglas utilizadas por el modelo, facilitando la identificación de relaciones entre las variables predictoras y el estado de diabetes.

- Puede visualizarse mediante herramientas como Tree Viewer de Orange Data Mining, lo que facilita el análisis de la estructura del modelo y la explicación de los resultados obtenidos.

El Árbol de Decisión resultó apropiado porque permite analizar la influencia de múltiples variables sobre la clasificación final y facilita la interpretación de los resultados obtenidos. Esto resulta especialmente útil en el contexto del proyecto, ya que no solo interesa predecir el estado de diabetes de una persona, sino también identificar cuáles son los factores que presentan una mayor asociación con dicha condición.


Además, esta técnica permite visualizar de manera clara las reglas generadas por el modelo, facilitando el análisis de los patrones identificados durante el proceso de clasificación y su comparación con los resultados obtenidos en las etapas exploratorias desarrolladas en las evidencias anteriores.

Por estas razones, se consideró que el Árbol de Decisión constituye una alternativa adecuada para construir un modelo predictivo que permita analizar la relación entre variables como BMI, edad, actividad física y tabaquismo con el estado de diabetes de la población estudiada.

7. Construcción y aplicación del modelo

El modelo predictivo fue construido utilizando la herramienta Orange Data Mining.

Para ello se diseñó un flujo de trabajo orientado a la preparación, entrenamiento, evaluación e interpretación del modelo de clasificación.



El flujo implementado se compuso de los siguientes componentes:

- **File:** utilizado para cargar el dataset preparado en las evidencias anteriores.
- **Select Columns:** utilizado para definir la variable objetivo y las variables predictoras que participarían en el proceso de clasificación.
- **Tree:** utilizado para construir el modelo de Árbol de Decisión.
- **Test and Score:** utilizado para evaluar el desempeño del modelo mediante métricas de clasificación.
- **Confusion Matrix:** utilizado para analizar los aciertos y errores de clasificación entre las distintas categorías de la variable objetivo.
- **Tree Viewer:** utilizado para visualizar e interpretar la estructura del Árbol de Decisión generado.

El proceso realizado consistió en cargar el dataset preparado, seleccionar las variables relevantes para el análisis y construir el modelo predictivo utilizando la técnica de Árbol de Decisión. Posteriormente, se evaluó el desempeño del modelo mediante métricas de clasificación y se analizaron los resultados obtenidos a través de la matriz de confusión y la visualización del árbol generado.

En el widget **Select Columns**, la configuración utilizada fue:

Rol	Variable
Target	Estado_Diabetes_Descripcion
Feature	BMI
Feature	Edad
Feature	Actividad_Fisica
Feature	Fumador

8. Evaluación del modelo

Para evaluar el desempeño del modelo se utilizaron métricas de clasificación obtenidas mediante la herramienta Test and Score de Orange Data Mining.

Métrica	Resultado
AUC	0,738
Accuracy / CA	0,842
F1 Score	0,774

Precisión	0,773
Recall	0,842
MCC	0,054

Test and Score:

4. Evaluación del modelo - Orange

☐ Cross validation
 Number of folds: 5
☒ Stratified

☐ Cross validation by feature

☒ Random sampling
 Repeat train/test: 5
 Training set size: 40 %
☒ Stratified

☐ Leave one out
☐ Test on train data
☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Arbol de Decision - Diabetes BRFSS 2015	0.738	0.842	0.774	0.773	0.842	0.054

Compare models by: Area under ROC curve ☐ Negligible diff.: 0.1

Arbol de De...

Arbol de Decision - Diabetes BRFSS 2015

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

254k | 761k | 1x761040

La métrica Accuracy (CA) obtuvo un valor de 0,842, lo que indica que el modelo clasificó correctamente aproximadamente el 84,2% de los registros analizados.

La métrica Precision alcanzó un valor de 0,773, indicando que el 77,3% de las predicciones realizadas por el modelo fueron correctas.

Por su parte, Recall obtuvo un valor de 0,842, lo que significa que el modelo logró identificar correctamente una alta proporción de los casos reales presentes en el dataset.


El F1 Score fue de 0,774, reflejando un equilibrio aceptable entre precisión y sensibilidad del modelo.

La métrica AUC alcanzó un valor de 0,738, lo que indica una capacidad aceptable para diferenciar entre las distintas categorías del estado de diabetes.

Finalmente, el coeficiente MCC obtuvo un valor de 0,054. Este resultado sugiere que, si bien el modelo presenta una buena exactitud general, su desempeño disminuye al considerar el desbalance existente entre las clases. Esto ocurre porque la categoría "No diabetes" representa la mayor parte de los registros del dataset, mientras que las categorías "Prediabetes" y "Diabetes" poseen una menor representación.

Además de las métricas de clasificación, se utilizó la matriz de confusión para analizar con mayor detalle los aciertos y errores del modelo en cada categoría de la variable objetivo.

Matriz de Confusión:



Al analizar la matriz de confusión, se observa que el modelo identifica correctamente una gran cantidad de registros correspondientes a la categoría "No diabetes". Sin embargo, presenta dificultades para clasificar adecuadamente las categorías "Prediabetes" y "Diabetes", generando errores entre estas clases minoritarias.

Este comportamiento es consistente con el desbalance presente en el dataset y explica por qué la Accuracy alcanza valores elevados mientras que métricas más exigentes, como MCC, muestran resultados considerablemente menores. Por este motivo, resulta importante complementar la evaluación utilizando múltiples métricas y no basarse únicamente en el porcentaje general de aciertos.

9. Interpretación de resultados

Los resultados obtenidos deben interpretarse considerando el desbalance existente en la variable objetivo. En el dataset analizado, la mayoría de los registros

corresponde a personas sin diabetes, mientras que las categorías de prediabetes y diabetes presentan una menor cantidad de casos.

Esta distribución desigual explica por qué el modelo obtuvo una Accuracy elevada (84,2%), pero un valor de MCC considerablemente menor (0,054). Esto indica que el modelo clasifica correctamente una gran proporción de los registros, aunque presenta mayores dificultades para distinguir adecuadamente las clases minoritarias.


El análisis de la matriz de confusión permite observar este comportamiento con mayor detalle. La mayoría de los registros pertenecientes a la categoría "No diabetes" fueron clasificados correctamente, mientras que las categorías "Prediabetes" y "Diabetes" presentan una menor capacidad de detección y una mayor proporción de errores de clasificación.

Por otra parte, el Árbol de Decisión generado muestra que las primeras divisiones se realizan principalmente utilizando las variables BMI y Edad. Esto indica que dichas variables poseen una influencia significativa en la clasificación del estado de diabetes dentro del conjunto de datos analizado.

Estos resultados son consistentes con los hallazgos obtenidos durante el análisis exploratorio realizado en las evidencias anteriores, donde se observó una mayor presencia de diabetes en personas con índices de masa corporal más elevados y pertenecientes a grupos etarios de mayor edad.

En consecuencia, el modelo no solo permite realizar predicciones sobre el estado de diabetes, sino también identificar factores relevantes asociados a esta condición, aportando información útil para el análisis y la comprensión del problema estudiado.

Tree Viewer:



10. Relación con el problema planteado

El modelo predictivo desarrollado permite complementar y reforzar el análisis realizado en las evidencias anteriores. Mientras que en las etapas iniciales el trabajo se enfocó en la exploración, limpieza y comprensión de los datos, en esta evidencia se avanzó hacia la construcción de un modelo capaz de clasificar individuos según su estado de diabetes a partir de variables relacionadas con su condición física y hábitos de vida.

Los resultados obtenidos muestran que variables como el índice de masa corporal (BMI) y la edad poseen una influencia relevante en la clasificación realizada por el modelo, lo que coincide con los patrones identificados durante el análisis exploratorio previo. Esto permite validar, desde una perspectiva predictiva, algunas de las relaciones observadas en el conjunto de datos.

La posibilidad de estimar el estado de diabetes a partir de factores como BMI, edad, actividad física y tabaquismo permite vincular el análisis de datos con potenciales aplicaciones en el ámbito de la salud preventiva. La identificación

temprana de personas con características asociadas a un mayor riesgo podría contribuir al diseño de estrategias de prevención, concientización y promoción de hábitos saludables.

No obstante, el modelo debe interpretarse como una herramienta de apoyo para el análisis de datos y no como un instrumento de diagnóstico médico. Su principal utilidad radica en la identificación de patrones generales y grupos de riesgo dentro de la población analizada, aportando información que puede resultar valiosa para futuras investigaciones o iniciativas de prevención.

11. Propuesta de decisiones o acciones

A partir de los resultados obtenidos mediante el modelo predictivo y del análisis realizado sobre el dataset, se proponen las siguientes acciones:

En primer lugar, priorizar campañas de prevención y concientización orientadas a personas con índices de masa corporal elevados y pertenecientes a grupos etarios de mayor edad. Estas variables mostraron una influencia significativa en la clasificación realizada por el modelo y coinciden con los patrones observados durante el análisis exploratorio.

En segundo lugar, fortalecer programas destinados a promover la actividad física y la adopción de hábitos saludables, especialmente en sectores de la población con estilos de vida sedentarios. La actividad física constituye un factor relevante dentro del análisis y representa una variable potencialmente modificable mediante intervenciones preventivas.

Asimismo, los resultados sugieren la conveniencia de implementar estrategias de detección temprana en grupos con características asociadas a un mayor riesgo de diabetes. En este contexto, los modelos predictivos podrían utilizarse como

herramientas de apoyo para identificar segmentos de población que requieran controles preventivos o seguimiento médico más frecuente.

Por otra parte, se recomienda continuar perfeccionando el modelo incorporando variables adicionales disponibles en el dataset original, tales como presión arterial alta, colesterol elevado, estado general de salud, dificultad para caminar o antecedentes de enfermedades cardiovasculares. La inclusión de estas variables podría contribuir a mejorar la capacidad predictiva del modelo y proporcionar una visión más completa de los factores asociados a la diabetes.

Finalmente, considerando las dificultades observadas para identificar correctamente los casos de prediabetes, se sugiere explorar técnicas de balanceo de clases y comparar el desempeño del Árbol de Decisión con otros algoritmos de clasificación. Esto permitiría evaluar alternativas capaces de mejorar la detección de categorías minoritarias y obtener resultados más robustos.

12. Herramientas utilizadas

Las herramientas y componentes utilizados fueron los siguientes:

- Orange Data Mining: herramienta principal utilizada para construir el flujo de trabajo predictivo.
- File: componente utilizado para cargar el dataset preparado del proyecto sobre indicadores de salud y diabetes.
- Select Columns: componente utilizado para definir la variable objetivo y las variables predictoras del modelo.
- Data Table: componente utilizado para visualizar el dataset cargado y verificar que las variables seleccionadas correspondieran al análisis.

- Tree: componente utilizado para construir el modelo predictivo mediante un Árbol de Decisión.
- Test and Score: componente utilizado para evaluar el desempeño del modelo mediante métricas de clasificación como Accuracy, Precision y Recall.
- Confusión Matrix: componente utilizado para analizar los aciertos y errores del modelo en cada categoría de la variable objetivo.
- Tree Viewer: componente utilizado para visualizar el Árbol de Decisión generado y facilitar la interpretación del modelo.
- Repositorio: https://github.com/emirobles/ISPC-Mineria_de_datos-2026

También se utilizó el dataset Diabetes Health Indicators Dataset, correspondiente a indicadores de salud asociados a diabetes, hábitos de vida y condiciones físicas de la población.

13. Conclusión

En esta tercera evidencia se aplicó una técnica predictiva de clasificación sobre el dataset previamente preparado. Se seleccionó como variable objetivo el estado de diabetes y se construyó un modelo basado en Árbol de Decisión utilizando variables relacionadas con el índice de masa corporal, la edad, la actividad física y el tabaquismo.

El desarrollo de esta evidencia permitió completar el proceso de minería de datos iniciado en las etapas anteriores. Mientras que en las primeras evidencias se realizó la comprensión del problema, la exploración de los datos y la preparación del dataset, en esta instancia se avanzó hacia la construcción y evaluación de un modelo predictivo capaz de clasificar nuevos casos.

Los resultados obtenidos mostraron que variables como el índice de masa corporal (BMI) y la edad poseen una influencia relevante en la clasificación realizada por el modelo, lo que resulta consistente con los patrones identificados durante el análisis exploratorio. Asimismo, el modelo alcanzó una Accuracy del 84,2%, evidenciando una buena capacidad general de clasificación sobre los datos analizados.

Sin embargo, los resultados deben interpretarse con precaución debido al desbalance existente entre las clases, especialmente por la baja proporción de casos de prediabetes frente a la categoría mayoritaria de personas sin diabetes. Esta situación se refleja en las dificultades observadas para detectar correctamente algunas clases minoritarias, por lo que resulta necesario complementar la evaluación mediante métricas como Precision, Recall, F1 Score, AUC, MCC y el análisis de la matriz de confusión.

Finalmente, este trabajo permitió comprobar cómo las técnicas de minería de datos pueden utilizarse para identificar patrones relevantes y generar conocimiento útil a partir de grandes volúmenes de información. Como línea de trabajo futuro, se propone incorporar nuevas variables disponibles en el dataset original y comparar el desempeño del Árbol de Decisión con otros algoritmos de clasificación, como Random Forest o Regresión Logística, con el objetivo de mejorar la capacidad predictiva del modelo y obtener resultados más robustos.

14. Bibliografía

- Teboul, A. (s. f.). *Diabetes Health Indicators Dataset*. Kaggle.
<https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>

- Centers for Disease Control and Prevention. (2015). *Behavioral Risk Factor Surveillance System (BRFSS)*. CDC.
- Orange Data Mining. (s. f.). *Orange Visual Programming Documentation*.
- Normas APA, 7.ª edición.

15. Anexos

Código en Python:

```
# =====  
# Modelo y métricas similares a Orange  
# =====  
from sklearn.model_selection import StratifiedKFold, cross_val_predict  
from sklearn.tree import DecisionTreeClassifier  
from sklearn.metrics import (  
    accuracy_score,  
    precision_score,  
    recall_score,  
    f1_score,  
    matthews_corrcoef,  
    roc_auc_score  
)  
import pandas as pd  
# Features y target como en Orange  
X = df[["BMI", "Smoker", "PhysActivity", "Age"]]  
y = df["Diabetes_012"]  
# Modelo con parámetros similares a los que se ven en Orange  
modelo_orange = DecisionTreeClassifier(  
    criterion="gini",  
    max_depth=5,  
    min_samples_leaf=100,  
    min_samples_split=5,  
    random_state=42  
)  
  
# Cross Validation como Orange
```

```
cv = StratifiedKFold(  
    n_splits=10,  
    shuffle=False  
)  
# Predicciones  
y_pred_cv = cross_val_predict(  
    modelo_orange,  
    X,  
    y,  
    cv=cv  
)  
# Probabilidades para AUC  
y_proba_cv = cross_val_predict(  
    modelo_orange,  
    X,  
    y,  
    cv=cv,  
    method="predict_proba"  
)  
# Métricas  
auc = roc_auc_score(  
    y,  
    y_proba_cv,  
    multi_class="ovr",  
    average="weighted"  
)  
ca = accuracy_score(y, y_pred_cv)  
f1 = f1_score(  
    y,  
    y_pred_cv,  
    average="weighted",  
    zero_division=0  
)  
precision = precision_score(  
    y,  
    y_pred_cv,  
    average="weighted",
```

```
zero_division=0
)
recall = recall_score(
    y,
    y_pred_cv,
    average="weighted",
    zero_division=0
)
mcc = matthews_corrcoef(y, y_pred_cv)
metricas_orange = pd.DataFrame({
    "Métrica": ["AUC", "CA / Accuracy", "F1", "Precision", "Recall", "MCC"],
    "Resultado": [auc, ca, f1, precision, recall, mcc]
})
metricas_orange["Resultado"] = metricas_orange["Resultado"].round(4)
display(metricas_orange)
```

[71]

...	Métrica	Resultado
0	AUC	0.7430
1	CA / Accuracy	0.8420
2	F1	0.7735
3	Precision	0.7710
4	Recall	0.8420
5	MCC	0.0524